

Estado del arte: control de misiones agenticas, trazabilidad y supervision humana

Sistema Operativo de Tesis de Posgrado

31 de mayo de 2026

Resumen

Los sistemas multiagente recientes desplazan el problema desde “generar una respuesta” hacia coordinar tareas, herramientas, memoria, permisos y evidencia. En un sistema de tesis, el control de misiones debe priorizar trazabilidad y control humano sobre autonomia total.

Hallazgos

1. La verificacion multiagente y los patrones de test-time compute muestran valor al separar generadores, revisores y verificadores.
2. Las arquitecturas agenticas modernas requieren limites explicitos: permisos por herramienta, logs, presupuestos, timeouts y recuperacion ante fallo.
3. La supervision humana debe quedar modelada como protocolo, no como comentario: una tarea puede ser auditada por IA, pero la validacion formal requiere consentimiento humano y Step ID.
4. Mission Control debe almacenar misiones, estados, evidencias, artefactos y bloqueos sin ocultar incertidumbre ni convertir resultados parciales en cierre.

Implicaciones para el Centro de Control

El Centro de Control debe operar como interfaz soberana: recibir misiones, crear entregables verificables, disparar pruebas, registrar evidencia y presentar bloqueos. Para trabajos academicos, cada mision debe terminar con rutas de `.tex`, `.pdf`, fuentes usadas, log de compilacion y estado de auditoria.

Referencias seleccionadas

- Multi-Agent Verification: Scaling Test-Time Compute with Multiple Verifiers, arXiv:2502.20379.
- MetaGPT: Meta Programming for a Multi-Agent Collaborative Framework, arXiv.
- Stanford CRFM HELM, enfoque de evaluacion transparente y reproducible.
- ISO/IEC 25059:2023, modelo de calidad para sistemas de IA.