

Estado del arte: inferencia edge hibrida local–nube

Sistema Operativo de Tesis de Posgrado

31 de mayo de 2026

Resumen

La inferencia edge contemporanea se organiza como continuo local–edge–cloud. El criterio tecnico dominante no es ejecutar el modelo mas grande en el borde, sino colocar cada tarea donde minimiza latencia, costo, riesgo de privacidad y consumo energetico.

Hallazgos

1. La literatura 2025 sobre edge intelligence enfatiza compresion de modelos, aceleradores dedicados y evaluacion por restricciones reales de memoria, energia y temperatura.
2. El offloading edge–cloud se usa cuando la tarea excede al nodo local o requiere modelos de razonamiento pesado.
3. Para equipos con GPU local, llama.cpp/Ollama y modelos GGUF cuantizados siguen siendo una ruta practica para privacidad y costos bajos.
4. La nube debe reservarse para validacion cruzada, modelos multimodales pesados o tareas publicas/redactadas.

Estado operativo en Tezkatli

El carril local validado usa llama.cpp en Docker CUDA, expuesto en 127.0.0.1:8085/v1, con el modelo DeepSeek-R1-Distill-Qwen-7B-Q4_K_M.gguf. El carril nube validado usa Gemini 2.5 Flash para contenido academico publico o redactado. El nodo NPU edge permanece experimental hasta contar con modelo RKLLM convertido y benchmark valido.

Referencias seleccionadas

- Edge Intelligence: A Review of Deep Neural Network Inference in Resource-Limited Environments, Electronics 2025.
- Computation offloading in the edge-to-cloud compute continuum: a survey of federated architectural solutions, Cluster Computing 2025.
- MLCommons MLPerf Inference, metodologia de referencia para medicion reproducible.
- llama.cpp server, API compatible con OpenAI para inferencia local GGUF.